

Raport końcowy: Q-learning FrozenLake + MLflow

Maciej Bereda(s31616), Maciej Gozdalik(s30659), Yevhen Koval(s30874)

PBIO14, projekt zespołowy, 16 czerwca 2026

Celem projektu było porównanie wpływu hiperparametrów Q-learningu i prostego reward shapingu na skuteczność agenta w deterministycznym środowisku FrozenLake 4x4, a następnie wykonanie finalnego runa w Azure ML z rejestracją modelu w MLflow Model Registry.

1. Organizacja pracy

Osoba	Tor	Zakres
Maciej Bereda	A	learning rate alpha: baseline, alpha-0.1, alpha-0.5, alpha-0.9, reward-dziura
Maciej Gozdalik	B	discount gamma: gamma-0.5, gamma-0.9, gamma-0.99, reward-krok
Yevhen Koval	C + host	eksploracja epsilon: baseline, eps-decay-0.0005, eps-decay-0.05, eps-start-0.1 uruchomiony dwukrotnie; finalny run Azure ML/MLflow

2. Metoda


Każdy eksperyment trenował tablicę Q przez 500 epizodów. Metryka trening_ost100_% opisuje skuteczność w ostatnich 100 epizodach treningu, a eval_eps0_% oznacza ewaluację polityki greedy, czyli bez dalszej eksploracji. To rozróżnienie jest ważne: wariant może mieć bardzo dobrą finalną tablicę Q, ale niską metrykę treningową, jeśli epsilon nadal wymusza dużo losowych ruchów.

3. Scalone wyniki

Scalony plik wyników zapisano jako raport_final/wyniki_zespołu_scalone.csv oraz kopię wyniki_zespołu_scalone.csv w folderze głównym. Usunięto jeden duplikat runa gamma-0.9, ponieważ w CSV zespołu występował dwa razy z tymi samymi parametrami i wynikiem.

Autor	Tor	Wariant	α	γ	eps start	eps decay	Trening	Eval
Maciej Bereda	baseline	baseline	0.7	0.95	1	0.005	81%	100%
Yevhen Koval	baseline	baseline	0.7	0.95	1	0.005	84%	100%
Maciej Bereda	A	alpha-0.1	0.1	0.95	1	0.005	83%	100%
Maciej Bereda	A	alpha-0.5	0.5	0.95	1	0.005	92%	100%
Maciej Bereda	A	alpha-0.9	0.9	0.95	1	0.005	85%	100%
Maciej Bereda	A	reward-dziura	0.7	0.95	1	0.005	86%	100%
Maciej Gozdalik	B	gamma-0.5	0.7	0.5	1	0.005	79%	100%
Maciej Gozdalik	B	gamma-0.9	0.7	0.9	1	0.005	87%	100%
Maciej Gozdalik	B	gamma-0.99	0.7	0.99	1	0.005	85%	100%
Maciej Gozdalik	B	reward-krok	0.7	0.95	1	0.005	87%	100%
Yevhen Koval	C	eps-decay-0.0005	0.7	0.95	1	0.0005	5%	100%
Yevhen Koval	C	eps-decay-0.05	0.7	0.95	1	0.05	93%	100%
Yevhen Koval	C	eps-start-0.1-run1	0.7	0.95	0.1	0.005	94%	100%
Yevhen Koval	C	eps-start-0.1-run2	0.7	0.95	0.1	0.005	92%	100%

Skuteczność treningowa ostatnich 100 epizodów



Rysunek 1: Porównanie skuteczności treningowej w ostatnich 100 epizodach.

4. Analiza wyników

Najlepszą metrykę treningową uzyskał wariant `eps-start-0.1-run1` osoby Yevhen Koval: 94% treningowo oraz 100% w ewaluacji greedy. Średni baseline dla dostępnych runów zespołu wyniósł 82.5% treningowo, przy 100% w ewaluacji greedy.

W Torze A najlepszy był `alpha-0.5` z wynikiem 92% treningowo i 100% eval. Niższe `alpha=0.1` uczyło wolniej, a `alpha=0.9` nie dało wyraźnej przewagi nad baseline. Wariant `reward-dziura` poprawiał interpretacyjnie bezpieczeństwo, ale nie był lepszy od najlepszego `alpha`.

W Torze B wszystkie warianty zachowały 100% eval. Najstabilniej treningowo wypadł `gamma-0.9` oraz `reward-krok`, oba w okolicy 87%. `gamma-0.5` dawało słabszy sygnał odległej nagrody, co obniżyło trening do 79%.

W Torze C najlepiej wypadł `eps-start-0.1-run1` z 94% treningowo. Drugi przebieg tego samego wariantu uzyskał 92%, więc niska eksploracja początkowa była w tych warunkach powtarzalna. `eps-decay-0.0005` jest najciekawszym kontrprzykładem: eval greedy wynosi 100%, ale trening tylko 5%, ponieważ po 500 epizodach agent nadal mocno eksploruje.

5. Reward shaping

Reward shaping nie był konieczny do uzyskania polityki greedy 100% w deterministycznym FrozenLake. `reward-dziura=-1.0` i `reward-step=-0.01` są jednak przydatne interpretacyjnie: pierwsze wzmacnia unikanie dziur, drugie promuje krótszą trasę. W tych danych najlepszy wariant finalny nie wymagał zmiany nagród, dlatego konfiguracja finalna pozostawiła `reward_hole=0.0` i `reward_step=0.0`.

6. Konfiguracja finalna

Po porównaniu wyników wybrano wariant finalny z Toru C:

Parametr	Wartość	Parametr	Wartość
alpha	0.7	gamma	0.95
eps_start	0.1	eps_end	0.05
eps_decay	0.005	episodes	500
reward_goal	1.0	reward_hole	0.0


reward_step	0.0	wariant	final
-------------	-----	---------	-------

7. MLflow, bramka jakości i drift


Finalny run uruchomiono w Azure ML jako zespół--final w eksperymencie frozenlake-qlearning. Model frozenlake-qlearning-policy-zespół został zarejestrowany w Model Registry jako wersja 1. Bramka jakości została spełniona: eval_success_rate = 1.000.

Test driftu środowiska, czyli przejście z deterministycznego FrozenLake na wariant śliski, dał eval_success_rate_slippery = 0.038. Spadek z 100% do 3.8% oznacza, że polityka wytrenowana w jednym typie dynamiki środowiska nie przenosi się automatycznie na środowisko stochastyczne. W praktycznym MLOps taki spadek byłby sygnałem do monitoringu i retreningu.


8. Wybrane krzywe uczenia




Rysunek 2: alpha-0.5, Tor A




Rysunek 3: gamma-0.9, Tor B



Rysunek 4: eps-start-0.1-run1, Tor C




Rysunek 5: eps-decay-0.0005, Tor C




Rysunek 6: Krzywa finalnego runa zespół--final uruchomionego w Azure ML.


9. Zrzuty ekranu z Azure ML



Rysunek 7: Terminal Azure ML: finalny run zakończony, model zarejestrowany, metryki `eval_success_rate=1.000` i `eval_success_rate_slippery=0.038`.



Rysunek 8: Azure ML Studio: eksperyment frozenlake-qlearning na liście Jobs.



Rysunek 9: Szczegóły runa zespol--final: parametry finalne, metryki i link do zarejestrowanego modelu.

10. Ograniczenia

Eksperymenty wykonano na małym środowisku FrozenLake 4x4, dlatego wszystkie sensowne warianty osiągały 100% w ewaluacji greedy. Różnice między wariantami najlepiej widać w metryce treningowej i kształcie krzywych uczenia. Dla mocniejszych wniosków należałoby uruchomić więcej seedów, większą mapę oraz osobne porównanie w środowisku stochastycznym już na etapie treningu.

11. Załącznik: hipotezy i wnioski z runów

- **Maciej Bereda / baseline:** Hipoteza: spodziewam się, że wykonane zostanie ileś kroków i będę móc to porównywać z innymi ustawieniami. Wniosek: Wniosek: potwierdziło się to że otrzymałem punkt porównania.
- **Yevhen Koval / baseline:** Hipoteza: Baseline powinien nauczyć skutecznej polityki w deterministycznym FrozenLake, ale metryka treningowa będzie niższa przez eksplorację.. Wniosek: Polityka greedy osiągnęła 100.0%, a trening 84.0%; różnica wynika z eksploracji podczas uczenia. Zmiana względem baseline: +0.0 p.p..
- **Maciej Bereda / alpha-0.1:** Hipoteza: Spodziewam się, że model będzie uczyć się o wiele wolniej i krzywa będzie o wiele bardziej płaska. Wniosek: Wniosek: krzywa średniej kroczącej osiągnęła 20% skuteczności dopiero po epizodzie 100 i 60% skuteczności dopiero po epizodzie 200, ale końcowa metryka treningowa okazała się być nie gorsza od baseline.
- **Maciej Bereda / alpha-0.5:** Hipoteza: Spodziewam się, że model będzie uczyć się nadal wolniej od baseline ale szybciej od 0.1, i krzywa będzie pomiędzy nimi. Wniosek: Wniosek: krzywa średniej kroczącej osiągnęła 20% skuteczności dopiero po epizodzie 200, ale 60% skuteczności już po epizodzie 250, i końcowa metryka treningowa okazała się być powyżej 90%.
- **Maciej Bereda / alpha-0.9:** Hipoteza: Spodziewam się, że model wyuczy się poprawnej ścieżki bardzo szybko jeśli na nią trafi szybko, ale po poprzedniej próbie jestem przekonany o losowości w wynikach. Wniosek: Wniosek: krzywa średniej kroczącej osiągnęła 20% skuteczności przed epizodem 100 i 60% skuteczności przed epizodem 200, i końcowa metryka treningowa okazała się być nie gorsza od baseline, ale nie uznaję tego za znaczącą poprawę ponad baseline.
- **Maciej Bereda / reward-dziura:** Hipoteza: Spodziewam się, że model może wyuczyć się poprawnej ścieżki szybciej jeśli będzie unikać błędnych. Wniosek: Wniosek: krzywa średniej kroczącej oderwała się od 0 prawie od razu, osią-

gnęła 20% skuteczności przed epizodem 100 i 60% skuteczności przed epizodem 200, i końcowa metryka treningowa okazała się być nie gorsza od baseline. Uznaję że wynik $\alpha=0.5$ był dziwny.

- **Maciej Gozdalik / $\gamma=0.5$:** Hipoteza: za krótki sygnał. Wniosek: wpisz wniosek: czy hipoteza się potwierdziła i co zaobserwowałeś/aś.
- **Maciej Gozdalik / $\gamma=0.9$:** Hipoteza: Różnica względem baselinu będzie mała. Wniosek: Hipoteza się potwierdziła. Skuteczność parametru była bardzo bliskiej.
- **Maciej Gozdalik / $\gamma=0.99$:** Hipoteza: Agent nie rozróżnia drogi krótkiej od długiej. Wniosek: Hipoteza się potwierdziła. Agent prawie nie dyskutował - skuteczność spadła.
- **Maciej Gozdalik / reward-krok:** Hipoteza: Presja na krótkie trasy pomaga. Wniosek: Presja na krótkie trasy nie jest kluczowa - skuteczność podobna do baselinu.
- **Yevhen Koval / ϵ -decay-0.0005:** Hipoteza: Bardzo wolny spadek epsilon sprawi, że agent będzie dłużej błądził; eval greedy może być dobry, ale metryka treningowa ucierpi.. Wniosek: Polityka greedy osiągnęła 100.0%, a trening 5.0%; różnica wynika z eksploracji podczas uczenia. Zmiana względem baseline: +0.0 p.p. Bardzo wolny decay utrzymał eksplorację dłużej, więc wynik treningowy jest konserwatywny..
- **Yevhen Koval / ϵ -decay-0.05:** Hipoteza: Eksploracja zgasnie po kilkudziesięciu epizodach; jeśli agent wcześniej znajdzie cel, wynik treningowy będzie wysoki.. Wniosek: Polityka greedy osiągnęła 100.0%, a trening 93.0%; różnica wynika z eksploracji podczas uczenia. Zmiana względem baseline: +0.0 p.p. Szybki decay ograniczył losowe ruchy po znalezieniu ścieżki..
- **Yevhen Koval / ϵ -start-0.1-run1:** Hipoteza: Prawie brak eksploracji od startu może utrudnić naukę, ale losowe rozstrzyganie remisów w tabeli Q może uratować agenta.. Wniosek: Polityka greedy osiągnęła 100.0%, a trening 94.0%; różnica wynika z eksploracji podczas uczenia. Zmiana względem baseline: +0.0 p.p..
- **Yevhen Koval / ϵ -start-0.1-run2:** Hipoteza: Drugi przebieg sprawdza, czy wariant z niskim epsilon startowym jest powtarzalny, czy zależy od szczęścia w pierwszych epizodach.. Wniosek: Polityka greedy osiągnęła 100.0%, a trening 92.0%; różnica wynika z eksploracji podczas uczenia. Zmiana względem baseline: +0.0 p.p..